Domande di SQL e Database

1) Cos'è un Database?

Un database è un insieme di dati relazionati tra loro e organizzati in una determinata struttura, generalmente archiviati in un supporto informatico.

2) Qual è la differenza tra Database relazionali e Database non relazionali?

Nei database relazionali i dati sono organizzati in tabelle, nei database non relazionali i dati sono organizzati in strutture diverse dalle tabelle, ad esempio documenti in formato JSON o grafi.

3) Cos'è l'SQL?

L'SQL è il linguaggio di programmazione più utilizzato per gestire, interrogare, aggiornare e popolare i database relazionali. SQL è l'acronimo di Stuctured Query Language

4) Cos'è una query SQL?

Una query SQL è del codice nel linguaggio SQL che permette di interrogare le tabelle di un database relazionale per estrarre delle particolari informazioni di interesse.

5) Cosa sono i DBMS e gli RDBMS?

Sono sistemi di gestione di Database, cioè dei software che permettono di creare, gestire e interrogare un database. Gli RDBMS sono particolari DBMS relativi ai Database relazionali. DBMS sta per Database Management System, RDBMS sta per Relational Database Management System.

6) Quali sono i DBMS più famosi?

Tra gli RDBMS: Sql Server, Oracle, MySQL, PostgreSQL e DB2. Anche Microsoft Access può essere considerato entro certe limitazioni un RDBMS. Tra i non-RDBMS ricordiamo MongoDB e Neo4J.

7) Qual è la differenza tra WHERE e HAVING all'interno di una query SQL?

La WHERE è utilizzata per eseguire dei filtri prima di un raggruppamento dei dati. L'HAVING è utilizzata per eseguire dei filtri dopo un raggruppamento dei dati.

8) A cosa servono le JOIN SQL?

Le JOIN SQL servono a combinare i dati tra due tabelle diverse utilizzando una determinata condizione. Le Join possono essere eseguite anche tra CTE, Subquery o Viste. Ecco un esempio di JOIN SELECT * FROM Clienti AS C INNER JOIN Fatture AS F ON C.IdCliente = F.IdCliente;

9) Qual è la differenza tra INNER, LEFT, RIGHT e FULL JOIN?

L'INNER JOIN restituisce solo le combinazioni tra righe delle due tabelle che rispettano la condizione di Join inserita nella clausola ON.

La LEFT JOIN aggiunge all'output dell'INNER JOIN anche le righe della tabella a sinistra della LEFT JOIN che non trovano righe corrispondenti nella tabella di destra.

La RIGHT JOIN aggiunge all'output dell'INNER JOIN anche le righe della tabella a destra della RIGHT JOIN che non trovano righe corrispondenti nella tabella di sinistra.

La FULL JOIN aggiunge all'output dell'INNER JOIN anche le righe in più date dalla LEFT JOIN e dalla RIGHT JOIN.

10) Cos'è una Subquery?

La Subquery è una query SQL utilizzata all'interno di un'altra query. Generalmente sono utilizzate: - nella clausola FROM a posto di una tabella; - nella WHERE dopo una IN o un "=". Con alcune limitazioni, le subquery possono essere utilizzate anche in altri punti del codice SQL.

11) Qual è la differenza tra Subquery e CTE?

Le Subquery sono scritte all'interno (dentro) la query principale. Le CTE sono definite prima (in alto) della query principale. Ad esempio SELECT * FROM (SELECT * FROM Clienti) AS SubQuery;

WITH CTE AS (SELECT * FROM Clienti) SELECT * FROM CTE;

12) Considera la tabella Fatture(IdFattura, Importo, DataFattura). Scrivi la query per contare il numero di fatture dove la colonna Importo è NULL.

SELECT COUNT(*)

```
FROM Fatture

WHERE Importo IS NULL;
```

13) Considera le tabelle

Studenti(IdStudente,Nome,Cognome)

Esami(IdEsame,IdStudente,Voto)

Scrivi la query per estrarre IdStudente, Nome e Cognome dei studenti con una media superiore al 27.

```
SELECT S.IdStudente, S.Nome, S.Cognome

FROM Studenti AS S

INNER JOIN Esami AS E

        ON S.IdStudente = E.IdStudente

GROUP BY S.IdStudente, S.Nome, S.Cognome

HAVING AVG(E.Voto) > 27;
```

14) Considera le tabelle

Clienti(IdCliente,Nome,Cognome)

Fatture(IdFattura,IdCliente,Importo)

Scrivi la query per riportare l'elenco dei clienti (IdCliente, Nome e Cognome) con almeno una fattura di importo superiore a 10 euro.

```
SELECT DISTINCT C.IdCliente,

      C.Nome,

      C.Cognome

FROM Clienti AS C

INNER JOIN Fatture AS F

    ON C.IdCliente = F.IdCliente  WHERE F.Importo > 10;
```

15) Considera la tabella Fatture(IdFattura, IdCliente, DataFattura, Importo). Scrivi la query per estrarre per ogni cliente l'Id della fattura di importo maggiore. A parità di importo considera l'IdFattura più grande.

```
WITH     Fatture_con_rank AS (
        SELECT *,                    RANK() OVER(PARTITION BY IdCliente
                                      ORDER BY Importo DESC,                                    IdFattura
DESC) AS Rn
        FROM Fatture )
SELECT IdCliente, IdFattura
FROM Fatture_con_rank
WHERE Rn = 1;
```

16) Descrivi le tre fasi della progettazione di un Database.

Le tre fasi della progettazioni di un database sono:

- concettuale;

- logica;

- fisica.

L'output della progettazione concettuale è generalmente un diagramma Entità-Relazione. Se si sceglie di implementare il diagramma E-R in un database relazionale, allora l'output della progettazione logica è un insieme di tabelle e vincoli come chiavi primarie e chiavi esterne. Di conseguenza l'output della progettazione fisica sarà lo script SQL per generare le tabelle precedenti su un particolare RDBMS.

17) Quali figure geometriche sono solitamente usate nel diagramma E-R?

I rettangoli per le entità, le ellissi per gli attributi e i rombi per le relazioni.

18) Come traduciamo all'interno della progettazione logica una relazione molti a molti del diagramma E-R?

Con una nuova tabella che avrà come colonne le chiavi primarie delle entità che partecipano alla relazione, più eventuali attributi della relazione stessa.

19) Cos'è una chiave primaria?

La chiave primaria di una tabella è un vincolo per cui una colonna (o una combinazione di colonne) non può assumere lo stesso valore (o la stessa combinazione di valori) più di una volta. Oltre all'assenza di valori duplicati, in una chiave primaria non è permessa la presenza di NULL. Ad esempio nella tabella Clienti, è plausibile che la colonna IdCliente sia chiave primaria.

20) Cos'è una chiave esterna?

Una chiave esterna di una tabella è un vincolo per cui i valori presenti in una delle sue colonne (o combinazione di colonne) devono essere già presenti all'interno di una colonna (o combinazione di colonne) chiave primaria di un'altra tabella.

Ad esempio nella tabella Fatture è plausibile che la colonna IdCliente sia una chiave esterna che fa riferimento alla chiave primaria IdCliente della tabella Clienti.

21) Quante chiavi primarie ed esterne possono esserci in una tabella?

In una tabella può esserci solo una chiave primaria (anche se creata su una combinazione di colonne). In generale è buona regola che una tabella abbia sempre una chiave primaria. In una tabella può esserci un numero variabile di chiavi esterna (da nessuna a più di una).

22) Cos'è una vista?

Una vista è una query SQL salvata all'interno del Database e che può essere riutilizzata all'interno di altre query, come se fosse una subquery o una sorta di tabella virtuale. È importante ricordare che in una vista è salvato soltanto il codice, non i dati. Di conseguenza il contenuto della vista (o meglio, l'output della query salvata) dipenderà dal contenuto delle tabelle sottostanti.

23) Che tipo di relazione è plausibile che esista tra gli studenti e i corsi di un database che modella i dati di un'Università? Come la tradurresti con l'SQL in un database relazionale?

È molto probabile che si tratti di una relazione molti a molti: uno studente può essere iscritto a più corsi e un corso può essere frequentato da più studenti. In un database relazionale avrò allora tre tabelle:

```
CREATE TABLE Corsi (
    IdCorso INT NOT NULL PRIMARY KEY,
```

```
   NomeCorso VARCHAR(50));

CREATE TABLE Studenti (
   IdStudente INT NOT NULL PRIMARY KEY,
    Nome VARCHAR(50),
    Cognome VARCHAR(50));

CREATE TABLE StudentiCorsi (    IdStudente INT NOT NULL,
  IdCorso INT NOT NULL,
  PRIMARY KEY (IdStudente,IdCorso),
  FOREIGN KEY (IdStudente)
     REFERENCES Studenti(IdStudente),
  FOREIGN KEY (IdCorso)
    REFERENCES Corsi(IdCorso));
```

24) Scrivi il codice SQL per aggiornare definitivamente sul Database con il valore Nicola la colonna Nome del cliente con IdCliente = 7.

```
UPDATE Clienti
SET        Nome = 'Nicola'
WHERE   IdCliente = 7;
```

25) Scrivi il codice SQL per eliminare definitivamente dal Database le fatture dei clienti residenti in Lombardia.

```
DELETE
FROM     Fatture
WHERE IdCliente IN (SELECT IdCliente
                              FROM Clienti
```

```
WHERE RegioneResidenza  = 'Lombardia');
```

26) Cosa si intende con Data Cleaning (pulizia dei dati)? Quali sono alcune tipiche attività di Data Cleaning e quali funzioni SQL puoi utilizzare?

Con Data Cleaning o "pulizia dei dati" si intende un insieme di attività e procedure svolte al fine di garantire che i dati, una volta importati, siano trasformati per raggiungere una struttura e una qualità minima necessaria per effettuare le operazioni successive di analisi.

Esempi di attività di Data Cleaning possono essere:

- uniformare separatori delle migliaia e delle cifre decimali per i numeri. Ad esempio potrei usare la funzione SQL REPLACE;

- eliminare spazi bianchi alle estremità di una stringa (usando ad esempio la funzione TRIM);

- estrarre solo particolari porzioni di una stringa (tramite SUBSTRING, LEFT, RIGHT, CHARINDEX);

- utilizzare dizionari comuni (ad esempio convertendo le stringhe "maschi" e "femmine" in "M" e "F" tramite CASE WHEN).

27) Come puoi convertire con l'SQL la stringa 2.032.010,31 nel numero decimale 2032010.31 gestendo dunque i separatori delle migliaia e dei decimali?

Tramite le funzioni REPLACE e CAST (o CONVERT):

```
SELECT CAST( REPLACE(  REPLACE ('2.032.010,31', '.', ''), ',', '.')  AS DECIMAL(18,2));
```

Domande di Excel

1) Qual è la differenza tra un riferimento relativo e un riferimento assoluto in una formula Excel?

Quando trascino dal bordo in basso a destra una cella contenente una formula (o equivalentemente se faccio copia & incolla), i riferimenti relativi contenuti in tale formula verranno aggiornati automaticamente, quelli assoluti NO.

Ad esempio, se trascino verso il basso una cella con la formula = B2+ C1 La parte della formula con il riferimento relativo B2 cambierà in automatico, quella con il riferimento assoluto

C1 no.

2) Quanti argomenti richiede la funzione Excel SE?

La funzione SE richiede tre argomenti:

- la condizione logica da verificare;
- cosa visualizzare quando la condizione logica nel primo argomento è vera;
- cosa visualizzare quando la condizione logica nel primo argomento è falsa.

Il secondo e il terzo argomento possono essere complessi a piacere, potrebbero contenere ad esempio un'ulteriore funzione SE.

3) Quale funzione di Excel permette di estrarre da un testo soltanto il terzo e il quarto carattere contenuto in una cella?

La funzione STRINGA ESTRAI, potrei scrivere ad esempio la formula =STRINGA.ESTRAI(A2,3,2)

4) A cosa serve il quarto argomento della funzione Cerca Verticale di Excel?

Il quarto argomento della funzione Cerca.Vert è molto importante. Nella grandissima maggioranza dei casi occorre ricordarsi di valorizzare tale argomento con il numero zero (o FALSO se Excel è in italiano): in questo modo Excel cercherà una corrispondenza esatta.

Se non valorizziamo il quarto argomento, il comportamento di default di Excel è di eseguire una ricerca approssimata, che molto spesso non è quello che servirà nelle nostre applicazioni.

5) Scrivi una formula Excel per contare il numero di righe con il valore "Lombardia" all'interno della colonna C.

=CONTA.SE(C:C; "Lombardia")

6) Quale funzione Excel devo utilizzare per calcolare delle somme che tengano conto delle righe filtrate o nascoste?

La funzione SUBTOTALE.

7) Posso applicare tramite la funzione FILTRO di Excel una condizione complessa che preveda due sotto condizioni da considerare in AND?

Sì, occorrerà inserire nel secondo argomento della funzione le due sotto-condizioni, racchiuderle entrambe tra parentesi e inserire tra di esse l'operatore * di moltiplicazione.

8) Quanti argomenti posso utilizzare nella funzione Excel PIU.SE?

Sostanzialmente tutti quelli che voglio, l'importante è che siano un numero pari. Infatti per ogni coppia di argomenti:

- il primo è il test logico da valutare;
- il secondo è cosa visualizzare se il test logico precedente risulta vero.

In realtà c'è un limite tecnico di 127 condizioni. Inoltre ricordiamo che la funzione PIU SE si "ferma" quando trova il primo test logico vero.

9) Qual è il risultato della formula Excel =SCARTO (B5;-1;1) ?

Il contenuto della cella C4 (una riga prima e una colonna dopo B5).

10) Quali sono le quattro possibili aree in cui trascinare i campi di una tabella pivot di Excel?
Righe, Colonne, Filtri e Valori.

11) Quale grafico reputi più idoneo a rappresentare una tabel-la Pivot di Excel che ha gli anni nelle righe e la somma delle spese nei valori?

Un grafico a linee, in modo da rappresentare adeguatamente l'andamento temporale delle spese, mettendo in luce trend, periodi di crescita, decrescita e poter valutare se inserire una linea di tendenza.

12) Una tabella Pivot di Excel contiene la categoria dei prodotti nei valori e la somma dei fatturati nei valori. Quale metodo ritieni più veloce per trasformare la somma dei fatturati in valori percentuali?

Fare click con il tasto destro del mouse su una delle celle contenenti la somma del fatturato, scegliere l'opzione "Mostra valori come" e in seguito "% del totale complessivo".

13) Occorre creare su Excel una tabella Pivot per mostrare la spesa totale al variare di anno e fornitore, considerando solo i prodotti di categoria A. Come configureresti la tabella Pivot?
Trascinerei l'anno nell'area delle righe, il fornitore nell'area delle colonne, la categoria prodotti

nell'area dei filtri e la spesa nell'area dei valori (assicurandomi di avere la somma impostata come funzione di aggregazione).

Configurerei infine il filtro per vedere solo i prodotti di categoria A. Potremmo anche pensare di portare sia l'anno e sia il fornitore nelle righe, stabilendo in questo modo una gerarchia nella visualizzazione e nelle somme.

14) Può aver senso in alcuni casi utilizzare una colonna numerica come "importo fattura" nell'area righe di una tabella Pivot di Excel?

Sì, a patto di raggruppare in intervalli i dati delle righe ottenute. Basta fare click con il tasto destro del mouse su un valore di riga, scegliere la voce raggruppa e configurare il numero di intervalli richiesti. In questo modo potrei ad esempio visualizzare il numero di fatture nelle fasce di importo 0-50 e 50-100.

15) Come si può abilitare l'opzione di calcolo Distinct Count (conteggio distinto) tra le opzioni di aggregazioni di una tabella Pivot?

Spuntando la casella "Aggiungi questi dati al modello dati" in fase di creazione della Tabella Pivot.

16) Nella cella A1 è riportata una formula di matrice dinamica (come ad esempio Unici, Filtro, DatiOrdinaPer, eccetera). Come posso riferirmi in un'altra cella all'intera risultato della formula in A1?

Utilizzando il simbolo #. Scriverò in particolare

=A1#

17) La colonna A contiene la tipologia di prodotto, la colonna B contiene l'importo e la colonna C contiene lo sconto. Nella colonna D voglio riportare l'importo meno lo sconto solo se la tipologia nella colonna A è uguale al valore "Premium", altrimenti voglio riportare semplicemente l'importo. Scrivi la relativa formula Excel.

=SE(A2 = "Premium"; B2 - C2; B2)

18) Mi descrivi una situazione in cui si genera un errore di #ESPANSIONE?

All'interno della colonna A del foglio1 sono presenti cinque valori distinti. Nella cella A1 del foglio2 scrivo la formula

=UNICI(Foglio1!A:A)

Tuttavia nella cella A3del foglio2 è già presente un valore testuale. In questo modo otterrò l'errore #ESPANSIONE.

19) Quale funzionalità di Excel posso utilizzare per inserire un menù a tendina per favorire l'inserimento dei dati in una cella?

Il tasto "Convalida dati" all'interno della scheda Dati. In particolare dovrò consentire di inserire i valori appartenenti ad un "Elenco".

20) Nella cella B3 scrivo questa formula =INDIRETTO(“B2”) Qual è il risultato della formula?

Il contenuto della cella B2.

Domande di Python e Machine Learning

1) Quali sono i principali formati di file che conosci e che puoi importare con la libreria Pandas?

I file CSV che generalmente hanno una riga di intestazione e contengono informazioni separate da un carattere delimitatore come la virgola o il punto e virgola.

Nome,Cognome,Eta

Nicola,Rossi,20 Giovanni,Verdi,25

I file JSON che contengono tra parentesi graffe un insieme di coppie "chiave-valore". I valori possono essere di vario tipo: stringhe, interi, array di valori (riconoscibili dalle parentesi quadre), sotto-documenti con ulteriori coppie "chiave-valore".

```
{"Nome"       : "Nicola",
 "Cognome" : "Rossi",
 "Eta"           : 20,
 "Telefono"   : ["3208321", "3208121"] }
```

I file .xlsx generato con Microsoft Excel.

Approfondimento: I file .xml che hanno delle caratteristi-che simili ai JSON ma una sintassi un po' più pesante perché le varie informazioni sono rappresentate tramite dei tag, ad esempio:

```
<cliente>
 <nome>Nicola</nome>
 <cognome>Rossi</cognome>
</cliente>
```

2) Cos'è un DataFrame?

Il DataFrame è la struttura dati in cui sono salvati generalmente i dati tramite la libreria Pandas di Python. Un Dataframe ha una struttura simile ad una tabella: le colonne hanno un nome e un tipo associato (come int, datetime, object), le righe hanno un ordine (è possibile ad esempio accedere alla "prima riga" del Dataframe) e hanno un index associato.

3) Come faccio ad ottenere l'elenco delle colonne e dei tipi di un Dataframe di nome df?

Tramite df.columns, df.dtypes o df.info()

4) Quale metodo di pandas utilizzi per leggere un file csv?

Il metodo read_csv.

5) Come faccio a leggere il contenuto di un file con Python senza la libreria pandas?

Con la funzione di python open. Ad esempio

```
with open ("file.txt",r) as f:
   testo = f.read()
```

6) Come puoi visualizzare le prime 10 righe del dataframe df?

Con il metodo df.head(10)

7) Come puoi ricavare le righe del Dataframe clienti dove la colonne nome è Nicola?

clienti[clienti["Nome"] == "Nicola"]

oppure

```
clienti.query("Nome == 'Nicola' ")
```

8) Come puoi visualizzare i principali indici statistici associati ad ogni colonna di un Dataframe?

Con il metodo describe().

9) Come puoi combinare i dati del Dataframe Fatture con quelli del Dataframe Clienti?

Tramite il metodo merge. Ad esempio:

```
pd.merge(fatture,  clienti, how = 'left',  left_on = "IdCliente", right_on = "IdCliente")
```

10) Crea un dataframe con la colonna Nome contenente i valori Nicola, Alberto e Giovanni.

Ecco una possibile soluzione. Per prima cosa posso creare una lista con quei nomi e poi utilizzo il metodo DataFrame di Pandas.

```
import pandas as pd

lista_nomi = ['Nicola','Alberto','Giovanni']

df = pd.DataFrame(data = lista_nomi , columns = ['Nome'] )
```

11) Crea una funzione con Python che prenda in input due numeri e restituisca la relativa somma

```
def somma(x,y):

  return x+y
```

12) Cosa sono oggetti e classi nell'ambito della programmazione a oggetti?

Una classe è un costrutto, un tipo di dati astratto, formato da attributi e metodi, che fungerà da modello per la creazione di oggetti. Un oggetto è un'istanza di una classe, una sua rappresentazione concreta.

Ad esempio, posso definire la classe astratta dei quadrati con l'attributo lato e il metodo perimetro e, a partire da essa, istanziare l'oggetto A come il quadrato di lato 7 o l'oggetto B come il quadrato di lato 5.

13) Qual è la differenza tra attributi e metodi di una classe?

Gli attributi sono le proprietà o le caratteristiche generiche della classe, i metodi sono le funzioni o le operazioni che un oggetto della classe può compiere. Ad esempio nella classe Cerchio la misura del raggio è un attributo, mentre il calcolo dell'area o della circonferenza sono metodi.

14) Crea su Python una classe quadrato con l'attributo lato e due metodi per calcolare l'area e il perimetro.

```
class Quadrato():
  def __init__(self, lato):
    self.lato = lato
   def area(self):
     return self.lato * self.lato
  def perimetro(self):
      return self.lato * 4
```

15) Considera questa classe su Pyton

```
class Quadrato():
  def __init__(self, lato):
    self.lato = lato
 def area(self):
    return self.lato * self.lato
 def perimetro(self):
   return self.lato * 4
```

Instanzia un oggetto della classe quadrato con lato 5 e calcolare l'area.

```
Q = Quadrato(5)
Q.area()
```

16) Cos'è un algoritmo di classificazione supervisionata?

Un algoritmo che ha l'obiettivo di predire il valore di una variabile target di tipo qualitativo (ad esempio la specie di un fiore nel famoso Dataset Iris, oppure "vero" o "falso" se la variabile target è dicotomica) a partire da una serie di variabili features.

La classificazione si dice supervisionata se per creare la formula di predizione utilizzo una serie di dati di training dove la variabile è target è già valorizzata.

17) Conosci alcuni algoritmi di classificazione supervisionata?

Sì, ad esempio il perceptron, la regressione logistica, la discesa stocastica del gradiente (SGD), gli alberi decisionali, le random forest, il knn (K-nearest neighbors).

18) Conosci una libreria di Python in cui sono implementati algoritmi di classificazione supervisionata?

Una libreria famosa in tale ambito è scikit-learn.

19) Come puoi suddividere il tuo dataset in una porzione di training e una porzione di test? Perché viene svolta questa operazione?

Posso utilizzare il metodo train_test_split del modulo model_selection della libreria scikit-learn. Quando creo un modello di Machine Learning è fondamentale tenere da parte una porzione dei dati (solitamente il 30%) e utilizzare soltanto la parte restante per addestrare l'algoritmo. In questo modo potrò utilizzare i dati di test per verificare l'accuratezza del modello su nuovi dati che non ha visto nella fase di addestramento.

Valutare l'accuratezza sugli stessi dati che ho usato per l'addestramento è sbagliato: potrei ottenere generalmente dei valori molto alti, ma senza avere nessuna certezza sul fatto che questi risultati si ripetano anche quando l'algoritmo si trova di fronte nuovi dati (questo fenomeno è detto overfitting).

20) Cos'è la standardizzazione (o scaling) di una variabile?

La standardizzazione è generalmente una delle fasi del pre-processing, cioè di quelle attività propedeutiche all'addestramento di un algoritmo di Machine Learning. In particolare tramite la normalizzazione riduciamo tutte le variabili quantitative ad una scala comune tramite delle trasformazioni matematiche.

Esistono varie tecniche di normalizzazione, una delle più comuni consiste nel sottrarre ad ogni numero la media della colonna e poi divere il risultato per la deviazione standard. In codice

```
from sklearn.preprocessing import StandardScaler

normalizzatore = StandardScaler()

 normalizzatore.fit(x1)

 x1 = normalizzatore.transform(x1)

 x2 = normalizzatore.transform(x2)
```

21) Scrivi il codice per addestrare un algoritmo di regressione logistica. Considera già terminata la fase di pre-processing. Calcola infine l'accuratezza sui dati di test.

```
from sklearn.linear_model import LogisticRegression

 lr = LogisticRegression()  lr.fit(x1,y1)

 y_pred_lr = lr.predict(x2)

 lr.score(x2,y2)
```

22) Che cos'è l'analisi dei dati esplorativa (EDA: Explorative Data Analysis)?

L'insieme di attività come il calcolo di indici statistici e le rappresentazioni grafiche che permettono di analizzare la distribuzione dei dati all'interno di un dataset, prima di applicare algoritmi di Machine Learning.

23) Come puoi studiare graficamente la distribuzione di una variabile quantitativa con Python e le sue librerie?

Posso disegnare il box-plot per individuare mediana, quartili e outlier e l'istogramma per studiare la distribuzione. Ad esempio, supponendo di studiare i dati del famoso dataset Titanic, potrei scrivere il codice seguente:

```
 import seaborn as sns

 g = titanic.boxplot(column = "age", figsize = (8,6))

 g = sns.histplot(data=titanic, x="age",kde=True)
```

24) Come puoi studiare la relazione esistente tra due variabili utilizzando Python e le sue librerie?

Se si tratta di variabili quantitative posso usare il metodo corr() di Pandas che permette di calcolare i coefficienti di correlazione. Il risultato può essere anche visualizzato tramite una mappa di colore (heatmap) con la libreria seaborn.

```
import seaborn as sns

 g = sns.heatmap(data = titanic.corr(), vmin=-1, vmax=1, annot=True, fmt=".1f",
linewidth=.5)
```

Anche le rappresentazioni grafiche possono essere di molto aiuto, ad esempio utilizzando il parametro hue che permette di colorare in modo diverso i dati per ogni classe di una variabile qualitativa

```
g = sns.catplot( data=titanic, x="embark_town", hue="survived", kind="count" )
```

25) Cos'è il processo di codifica delle variabili qualitative?

Sono quelle attività di pre-processing necessarie a rappresentare le variabili qualitative tramite dei numeri. Nel caso si tratti di una variabile qualitativa nominale (cioè in cui non è presente un modo esplicito di ordinare i dati) potrò eseguire con scikit-learn il OneHotEncoder che crea tante colonne per ogni possibile valore della variabile contenenti soltanto i valori zero o uno.

Nel caso si tratti di una variabile qualitativa ordinale allora potrò eseguire un OrdinalEncoder. Se ad esempio la variabile è il grado di istruzione potrò assegnare 1 al valore "licenza media", 2 al valore "diploma di scuola superiore" e 3 al valore "laurea".

26) Cos'è una pipeline di scikit-learn?

Puoi scrivere il codice per crearne una? In scikit-learn una pipeline è una serie di step costituiti generalmente da trasformazioni di pre-processing e un'algoritmo finale di predizione. Esse permettono di automatizzare con poche righe di codice l'esecuzione di modelli di Machine Learning e le relative attività di convalida dei dati e ottimizzazione dei parametri.

Ad esempio una semplice pipeline che può essere applicata ad un dataset con sole colonne numeriche è:

```
from sklearn.pipeline import Pipeline

my_pip = Pipeline([('pr',StandardScaler()), ('cl',SGDClassifier(random_state=0)) ])
```

27) Che cos'è la convalida incrociata dei dati?

È una metodologia di valutazione dell'accuratezza di un modello. Dividiamo i dati di training in un numero di parti (solitamente 5 o 10) ed eseguiamo ogni volta l'addestramento su tutte le parti tranne una e il test sulla parte restante. In questo modo avrò tante misure dell'accuratezza che poi potrò analizzare calcolandone la media e la deviazione standard.

Infine è sempre opportuno ri-addestrare l'algoritmo su tutti i dati di training e valutare l'accuratezza sui dati di test non utilizzati durante la convalida. In questo modo posso valutare se l'algoritmo si adatta bene a lavorare su dati mai visti in precedenza o se soffre di overfitting.

28) Come puoi ottimizzare i parametri di un modello di Machine Learning?

Tramite scikit-learn posso utilizzare GridSearchCV, passandogli in input una pipeline e una griglia di parametri. Ad esempio, riutilizzando la pipeline creata nella domanda 26, utilizzerò il codice:

```
param_grid = [{'sgd__eta0':[0,0.02,0.05]}]

my_grid = GridSearchCV(estimator = my_pipeline, param_grid = param_grid, cv = 10)

my_grid.fit(x1,y1)

my_grid.best_params_
```

Domande di Statistica

1) Fai un esempio di variabile qualitativa nominale, qualitativa ordinale, quantitativa discreta e quantitativa continua.

Il colore degli occhi è una variabile qualitativa nominale (non posso eseguire operazioni matematiche e non posso mettere un ordinamento sui valori che abbia senso).

Il grado di istruzione è una variabile qualitativa ordinale (non posso eseguire operazioni matematiche ma posso inserire un concetto di ordine, ad esempio licenza media < diploma scuola superiore < laurea).

Il numero di figli è una variabile quantitativa discreta (può assumere i valori interi tra zero e un numero sufficientemente piccolo come dieci).

La temperatura è una variabile quantitativa continua (può assumere valori continui, compresi tutti i possibili numeri decimali).

2) Qual è la differenza tra statistica descrittiva e statistica inferenziale?

La statistica descrittiva si limita a descrivere le osservazioni ottenute e a sintetizzarle tramite una serie di indici statistici. La statistica inferenziale parte dalle osservazioni di un campione e vuole dare delle stime sulle caratteristiche dell'intera popolazione da cui quel campione è stato estratto.

3) Quali sono le analogie e le differenze tra media aritmetica e mediana?

Media aritmetica e mediana sono entrambi indici di posizione centrale, il loro obiettivo è quello di riassumere una variabile statistica con un unico valore "centrale", che ci dia un'idea di massima dei dati presenti nella distribuzione.

A parte le modalità di calcolo che sono ovviamente diverse, la mediana è un indice meno sensibile alla presenza di outlier. Inoltre può essere calcolata anche per variabili qualitative ordinali, mentre la media aritmetica può essere calcolata solo per variabili quantitative.

4) Che cos'è un outlier? Faresti un esempio?

Gli outlier sono quei valori assunti da una variabile statistica che sono molto distanti dagli indici di posizione centrale. Ad esempio se la variabile X assume i valori 3, 5, 5, 2, 4, 40 possiamo supporre che il valore 40 sia un outlier.

Occorre fare attenzione alla loro presenza per svariati motivi:

- potrebbero compromettere il risultato delle analisi statistiche;

- si potrebbe trattare di semplici errori di misura o di imputazione da correggere (ad esempio si è riportato 40 invece di 4.0);

- nel caso non si tratti di semplici errori, gli outlier potrebbero essere relativi ad individui particolari che vale la pena approfondire.

5) Cos'è la deviazione standard?

La deviazione standard è un indice di variabilità per una variabile quantitativa. Ci indica la tendenza dei dati a variare, nella loro stessa unità di misura.

Ad esempio, se una variabile statistica ha media 10 e deviazione standard pari a 1, mi aspetto di trovare molte misurazioni dove la variabile assume valori vicino a 10, come 8, 9 o 11. Viceversa se un'altra variabile statistica ha la stessa media 10 ma deviazione standard pari a 8, mi aspetto di trovare tra le misurazioni anche valori molto distanti dalla media, come numeri negativi o numeri maggiori di 20.

6) Come posso confrontare la variabilità tra due variabili differenti?

Confrontare direttamente le deviazioni standard potrebbe essere sbagliato perché essa è legata all'unità di misura dei dati. È meglio utilizzare il coefficiente di variazione definito come la deviazione standard diviso il valore assoluto della media.

7) Conosci dei metodi per "scalare" le variabili (scaling) ad una stessa unità di misura?

Sì, si tratta di metodologie che spesso vanno applicate prima di alcuni algoritmi matematici di Machine Learning o di statistica. In questo modo si evita di lavorare su variabili che assumono valori molto distanti tra loro. Pensiamo ad esempio all'età misurata in anni che va da zero a cento circa, o il reddito annuo in euro che può arrivare anche oltre 100.000.

Due dei metodi più frequenti per effettuare lo scaling sono

x_new = (x_old - Media(X)) / Dev_ST(X)

cioè sottrarre ad ogni valore la media della colonna e dividere il risultato ottenuto per la deviazione standard.

Oppure

x_new = (x_old - x_min) / (x_max - x_min)

cioè sottrarre al vecchio valore il minimo della colonna e dividere questo risultato per la differenza tra il valore massimo e quello minimo.

8) Cosa sono gli indici di asimmetria di Fisher e gli indici di curtosi?

Si tratta di due indici di statistica univariata che descrivono la forma di una distribuzione statistica. L'indice di Fisher è pari a zero quando la variabile è perfettamente simmetrica. L'indice di curtosi vale zero quando la variabile ha una forma piatta come la normale.

9) Cosa misura l'indice chi quadrato?

L'indice chi quadrato misura il grado di associazione tra due variabili qualitative. In particolare la sua versione normalizzata (indice V di Cramer) è pari a 1 in caso di associazione massima.

10) Con quali indici posso calcolare il grado di associazione tra due variabili quantitative?

I due coefficienti più utilizzati sono il coefficiente di correlazione lineare di Person e il coefficiente di Spearman.

11) Quali valori può assumere il coefficiente lineare di Pearson?

Questo coefficiente può assumere valori tra -1 e 1. Dove -1 e 1 sono rispettivamente i valori di massima correlazione lineare indiretta e massima correlazione lineare diretta. Un coefficiente pari a zero indica assenza di correlazione lineare.

12) Possono esistere casistiche in cui il coefficiente di correlazione lineare di Pearson è prossimo a zero mentre il coefficiente di Spearman è vicino a 1?

Sì, se le due variabili sono legate da una relazione che non è di tipo lineare, ma ad esempio esponenziale.

13) Cosa sono i residui all'interno di un algoritmo di regressione?

La differenza tra i valori reali della variabile dipendente e i rispettivi valori calcolati tramite l'algoritmo di regressione.

14) Qual è la differenza tra stima puntuale e stima intervallare?

La stima puntuale di un parametro statistico è costituita da un solo numero (ad esempio il numero 5), la stima intervallare è costituita da un intervallo o range di numeri (ad esempio l'intervallo dei numeri compresi tra 3 e 7).

15) Come viene calcolata la stima puntuale della varianza di una popolazione a partire dai dati di un campione?

Moltiplicando la varianza calcolata considerando i soli dati del campione per un coefficiente correttivo di poco superiore a 1.

Per la precisione questo coefficiente è pari al rapporto tra il numero di elementi del campione e il numero di elementi meno 1, in formule

n / (n-1)

16) Quali tecniche posso utilizzare per verificare se un campione proviene da una popolazione normale?

Posso ottenere indicazioni in merito tramite metodi grafici (disegnando ad esempio l'istogramma o il q-q plot), calcolando gli indici di forma ed eseguendo test statistici come quello di Shapiro-Wilk.

17) Come posso calcolare l'intervallo di fiducia della media di una popolazione normale partendo dai dati di un campione?

Sotto l'ipotesi di normalità della popolazione di partenza, gli estremi dell'intervallo di fiducia possono essere calcolati con le formula:

media del campione - [(coefficiente legato alla variabile di Student e al livello di fiducia richiesto all'intervallo) * (stima della deviazione standard) / (radice quadrata della numerosità del campione)]

media del campione + [(coefficiente legato alla variabile di Student e al livello di fiducia richiesto all'intervallo) * (stima della deviazione standard) / (radice quadrata della numerosità del campione)]

8) Qual è il coefficiente di variazione di una variabile con media 10 e varianza 9?

Il coefficiente di variazione è pari alla deviazione standard diviso il valore assoluto della media. In questo caso la deviazione standard è 3 (pari alla radice quadrata della varianza 9), mentre la media è 10. Di conseguenza il coefficiente di variaizone è 0.3 o 30%.

19) Che cos'è un Boxplot?

Il Boxplot è una particolare rappresentazione grafica per una variabile quantitativa. Esso è costituito da:

- un rettangolo (la scatola) la cui altezza, se disegnato in verticale, corrisponde alla differenza interquartile. Quindi la base inferiore è pari al primo quartile mentre la base superiore è pari al

terzo quartile. All'interno del rettangolo è tracciata un'altra linea in corrispondenza della mediana e, in alcuni casi, un simbolo X in corrispondenza della media.

- delle linee verticali (i baffi) che partono dalle due basi. Non c'è una regola univoca per disegnare i baffi. Spesso si disegna la linea fino a quello specifico valore oltre il quale i dati sono considerati degli outlier (ad esempio il terzo quartile + 1.5 volte la differenza interquartile).

- i valori oltre i baffi (gli outlier) sono rappresentati tramite dei cerchi vuoti.

20) Qual è il soggetto del test statistico di Levene?

La varianza di una singola popolazione.

21) Con quale indice statistico misureresti il grado di associazione tra una variabile qualitativa e una quantitativa?

Tramite l'indice statistico Eta quadro.

Domande di MongoDB e database non relazionali

1) **Perché MongoDB è un database non relazionale?**

Perché al suo interno i dati non sono organizzati in ta-belle, ma in una struttura differente (documenti BSON).

2) **Quali sono le caratteristiche di un documento JSON?**

Un documento JSON è composto da un insieme di coppie formate da una chiave e un valore, con una sintassi ben precisa: il documento è racchiuso tra parentesi graffe, le chiave sono separate dai valori dal carattere ":" due punti, le coppie sono separate da una virgola.

3) Puoi scrivere un documento JSON d'esempio?

```
{"nome":"Nicola",
 "cognome":"Iantomasi",
 "email" : ["nicola.iantomasi@yimp.it","info@yimp.it"]
```

}

4) Cos'è il formato BSON?

Il BSON è il formato dati utilizzato dal database MongoDB per salvare i dati. Il formato BSON di MongoDB è strettamente legato al classico formato JSON. Le differenze principali riguardano:

- le modalità interne che usa MongoDB per salvare i dati efficientando la memoria utilizzata e gli algoritmi di ricerca;

- la possibilità di creare dei valori con dei tipi specifici come date e ObjectId non disponibili nel classico JSON.

La parola Bson sta per Binary-Json.

5) Come sono raggruppati i documenti BSON all'interno di un database di MongoDB? Che differenze ci sono con le tabelle del modello relazionale?

I documenti sono raggruppati all'interno di collection. Esse hanno un ruolo all'interno di MongoDB simile a quello delle tabelle di un database relazionale. Tuttavia ci sono tantissime differenze tra collection e tabelle.

In primo luogo le collection sono fatte da documenti BSON, mentre le tabelle sono composte da righe. Inoltre all'interno della stessa collection lo schema è dinamico: possono cioè sussistere documenti con un elenco differente di chiavi, oppure una chiave con lo stesso nome può avere più tipi differenti nella stessa collection.

6) Sai scrivere una query NoSQL per estrarre le chiavi nome e cognome della collection clienti di un database MongoDB, considerando soltanto i documenti dove l'eta è maggiore di 30?

```
db.clienti.find({"eta"        : {$gt : 30}},
                {"nome"      : true,
                 "cognome" : true,
                 "_id"          :  false} )
```

7) Cosa caratterizza le chiavi di tipo array o di tipo array associativo?

All'interno di un documento JSON le chiavi possono contenere più di un valore. In questo caso i valori sono racchiusi tra parentesi quadre e formano un array. Inoltre il valore di una chiave può essere a sua volta un "sotto-documento" JSON, quindi un altro insieme di coppie chiave-valore. In questo caso si parla di array associativi. Possiamo anche avere un caso "misto", in cui sono presenti array di sotto-documenti, come in questo esempio:

```
{"nome_corso" : "MongoDB",
 "docenti"      : [{"nome" : "Nicola",  "cognome" : "Iantomasi"},
                    {"nome" : "Giovanni",  "cognome"   : "Rossi"}
                   ] }
```

8) All'interno di un documento della collection corsi è presente una chiave di nome docente di tipo array associativo (o sotto-documento) contenente la sottochiave nome. Scrivi una query NoSQL per estrarre i documenti dove questa sottochiave è uguale a Nicola

```
db.corsi.find({"docente.nome" : "Nicola"});
```

9) Scrivi una query NoSQL per estrarre tutti i documenti della collection clienti dove è presente la chiave numero_telefono (anche se ha come valore null)

```
db.clienti.find({"numero_telefono" : {$exists : true}});
```

10) Descrivi le principali operazioni che può implementare all'interno del framework aggregate di MongoDB.

Le operazioni utilizzate più frequentemente sono:

- $match per eseguire dei filtri;
- $group per raggruppare i dati;
- $lookup per combinare i dati di più collezioni;
- $addFields per aggiungere chiavi calcolate con l'utilizzo di funzioni;
- $project per visualizzare in output soltanto alcune chiavi;
- $unwind per gestire chiavi di tipo array.

11) Traduci nella sintassi NoSQL di MongoDB la seguente query SQL:

SELECT Regione, COUNT(*) AS NumeroClienti

FROM Clienti

GROUP BY Regione;

```
db.clienti.aggregate( [ {$group : {"_id" : "$regione",
                                   "numero_clienti"  : {$sum:1}
                                   }
                        } ] );
```

12) Come posso combinare i dati di due differenti collection con MongoDB?

All'interno del metodo aggregate posso utilizzare l'operatore $lookup. Infatti, anche se il metodo aggregate risulta comunque applicabile ad una singola collezione, all'interno di esso posso fare riferimento ad una seconda collezione nell'operatore $lookup e specificare quale criterio utilizzare per combinare i dati.

13) Scrivi il codice per creare una nuova collezione di nome clienti.

```
db.createCollection("clienti");
```

14) Scrivi il codice per eliminare definitivamente da un database di MongoDB la chiave regione_residenza da tutti i documenti della collezione clienti.

```
db.clienti.updateMany({ },
                        {$unset :  {"regione_residenza" : true}      }
                        );
```

15) Qual è la differenza tra $push e $addToSet quando vogliamo aggiungere un nuovo valore ad un array?

Con $push il nuovo valore sarà sempre aggiunto in fondo all'array considerato, con $addToSet l'aggiunta verrà effettuata solo se tale valore non è già presente nell'array.

Domande di PowerBI

1) Che ruolo ha Power Query all'interno di un progetto di Business Intelligence con Power BI? Tramite Power Query è possibile acquisire dati da tantissime tipologie di fonti, tra cui i file con i formati più comuni come .csv, .xlsx e .json. Oltre all'importazione, Power Query ci permette di eseguire una ricca serie di operazioni di pulizia e trasformazione dei dati, ad esempio:

- filtrare e raggruppare i dati;

- associare un tipo ad ogni colonna;

- gestire gli errori;

- scegliere le colonne da importare.

2) È possibile usare Power Query per aggiungere ai dati importati delle nuove colonne calcolate?

Sì, all'interno di Power Query è presente una scheda del menù specifica per aggiungere nuove colonne. Posso ad esempio:

- creare una colonna condizionale il cui valore dipenda da un particolare test logico;

- aggiungere una colonna con una sequenza di numeri progressivi;

- utilizzare le formule di Power Query.

Nuove colonne possono essere generate anche in seguito tramite operazioni di trasformazione dei dati. Ad esempio, potrei utilizzare la funzionalità Dividi colonna per eseguire lo split di una colonna in base alla presenza di un carattere delimitatore.

3) Abbiamo la possibilità di inserire manualmente dei dati direttamente su Power Query?

Sì, per quanto lo strumento sia pensato principalmente per acquisire dati già generati tramite un altro software, è possibile anche inserire direttamente i dati creando una nuova tabella tramite il tasto "Immettere i dati".

4) Perché in alcune celle delle tabelle di Power Query appare la scritta error? Come gestisci questi casi?

Gli errori possono essere generati da varie cause, probabilmente il caso più comune è un errore nella conversione del tipo associato ad una colonna. Ad esempio, se impongo che una colonna

sia di tipo numero intero ma al suo interno è presente una stringa di testo, allora mi apparirà un errore.

In generale non c'è un modo univoco di gestire gli errori, dipenderà dal particolare progetto che stiamo svolgendo. Generalmente è una decisione da prendere in comune accordo con chi poi utilizzerà attivamente la Dashboard. Alcune strategie possibili sono:

- sostituire gli errori con un determinato valore;

- decidere di eliminare le righe o le colonne contenenti degli errori se non sono rilevanti ai fini della Dashboard;

- creare una tabella che riporti le sole righe in errore in modo da poter tenere sotto controllo la qualità dei dati;

- tramite la funzionalità "Immettere i dati" potremmo inserire manualmente i valori corretti e poi combinare queste informazioni con quelle del file di partenza tramite Power Query o le formule DAX.

5) Per quale motivo creiamo delle relazioni tra le tabelle di Power BI?

Creando delle relazioni possiamo analizzare e rappresentare contemporaneamente i dati che provengono da più tabelle, permettendo dunque un'analisi dei dati più ricca e significativa, senza la necessità di dover contenere tutte le informazioni in un'unica tabella.

6) È sempre possibile creare una relazione tra due tabelle?

No, per definire una relazione occorre indicare una colonna per ognuna delle due tabelle che partecipano alla relazione. Tali colonne non possono essere scelte a caso, ma devono essere idonee alla creazione di tale relazione.

Facciamo un esempio: per creare la relazione tra una tabella Fatture e una tabella Clienti potrei scegliere la colonna IdCliente che mi aspetto sia presente in entrambe le tabelle. Riprendendo il lessico dei database relazionali, IdCliente avrà il ruolo di chiave esterna nella tabella Fatture e di chiave primaria nella tabella Clienti.

7) Che cos'è il linguaggio DAX?

DAX è il particolare linguaggio utilizzato all'interno di Power BI per definire principalmente colonne calcolate, intere tabelle e misure. In questo modo possiamo trasformare ulteriormente i

dati ottenuti in output da Power Query e arricchire le possibilità di calcolo e aggregazioni all'interno delle dashboard.

8) Mi fai un esempio di utilizzo del linguaggio DAX?

Uno dei casi più semplici di utilizzo potrebbe essere aggiungere una colonna calcolata ad una tabella in cui estraiamo l'anno da una data completa. Mi basterà cliccare sul tasto "Nuova colonna" all'interno della visualizzazione della tabella e inserire una formula come

AnnoFattura = YEAR(DataFattura)

9) A cosa serve la formula DIVIDE?

Ad eseguire la classifica divisione tra due numeri o tra due colonne di una tabella, permettendoci però di definire nel terzo argomento il risultato da visualizzare nel caso il denominatore sia zero. Ad esempio la formula = DIVIDE(3,0,1) restituirà 1. Se non specifico il terzo argomento, in caso di divisione per zero con la funzione DIVIDE otterrò BLANK().

10) Quale tipologia di grafico utilizzeresti per evidenziare la relazione tra il contenuto delle colonne Prezzo e QuantitaVendute?

Trattandosi di due colonne numeriche (grandezze quantitative), potremmo utilizzare un grafico a dispersione per mettere in evidenza l'eventuale presenza di una relazione tra il prezzo e il numero di quantità vendute.

11) Mi mostri con un esempio la differenza tra una colonna calcolata e una misura?

Supponiamo di creare all'interno di una ipotetica tabella Vendite, una colonna calcolata con questa formula

ImpattoCommissioni = DIVIDE(Vendite[Commissioni], Vendite[SpesaTotale])

Quando all'interno di una Dashboard vado a raggruppare i dati per una dimensione di analisi (come ad esempio la Regione di vendita) e ad aggregare con una somma la colonna calcolata definita precedentemente, otterrò un valore privo di significato!

Sto andando tecnicamente a sommare una serie di rapporti relativi alla stessa regione, il risultato sarà un numero senza nessun significato.

Invece se definisco una misura in questo modo

MisuraImpattoCommissioni = DIVIDE(UM(Vendite[Commissioni]), SUM(Vendite[SpesaTotale]))

se raggruppo come prima per Regione di vendita e uti-lizzo la misura appena creata come campo, otterrò effettivamente per ogni regione un valore significativo! Esso sarà dato da un'unica frazione, con al denominatore la somma di tutte le spese (di quella regione) e al numeratore la somma di tutte le commissioni (sempre di quella regione).

Le misure possono essere utilizzate anche per calcoli più complessi, come ad esempio gli importi cumulati relativamente ad una data.

12) Che cos'è un albero di scomposizione in Power BI?

Un albero di scomposizione è una particolare rappresentazione grafica disponibile in Power BI. Permette di svolgere un'analisi gerarchica dei dati, mostrando come una particolare quantità numerica (ad esempio la somma degli importi) si suddivide in categorie e sottocategorie.

13) Come posso eliminare gli spazi bianchi superflui alla fine o all'inizio di una colonna contenente del testo?

Posso raggiungere questo obiettivo sia in Power Query, scegliere il pulsante "Formato"->"Taglio" dalla scheda "Trasforma" e sia tramato il linguaggio DAX con la funzione TRIM.

14) Qual è la differenza in Power Query tra le operazioni "Unisci Query" e "Merge di Query"?

Tramite "Unisci Query" possiamo unire in una sola ta-bella le righe di due query, le une sotto le altre. Solitamente le due query da unire hanno le stesse colonne, ad esempio Fatture2023 e Fatture2024.

Tramute "Merge di Query" possiamo unire in una sola tabella le righe di due query, le une accanto alle altre (non sotto), specificando una o più colonne tramite le quali effettuare il merge. Ad esempio possiamo effettuare il Merge tra le query Fatture e Clienti usando come colonna di riferimento per entrambe le query IdCliente.

15) Qual è l'obiettivo della misura seguente?

```
IF(COUNTROWS(Vendite)>0,
    CALCULATE(SUM(Vendite[SpesaTotale]),
                FILTER(ALL(Calendario[Date]),  Calendario[Date]<=  MAX(Calendario[Date]))),
```

BLANK())

Calcolare la somma progressiva (running total) dei valori presenti nella colonna Spesa Totale della tabella Vendite, al crescere della colonna Date. L'istruzione IF serve a non visualizzare le righe relative a date per le quali non sono presenti valori.

16) Che cos'è M nel contesto di Power BI?

Il linguaggio di formula di Power Query.

17) A cosa fa riferimento questa porzione di codice?
= Table.Group(#"Rimossi duplicati", {"Regione"}, {{"Ispettori", each Text.Combine([Ispettore],","), type nullable text}})

Ad una formula M all'interno di Power Query.

Domande di Data Management

1) Puoi dare una definizione di Data Management?

Con Data Management si intende l'insieme di tutte le attività che un'azienda fa con i propri dati, con il fine di proteggerli, rispettare le normative, supportare i processi e trasformarli in informazioni utili al processo decisionale.

2) Quali sono dei possibili errori nel processo di lavorazione dei dati in un'azienda?

Ecco alcuni esempi:

- i dati di partenza non sono corretti;

- i dati di partenza sono in un formato non utilizzabile per le analisi;

- i dati di partenza hanno dei valori mancanti;

- i dati di partenza non sono più disponibili;

- ci sono degli errori negli algoritmi di integrazione dei dati;

- ci sono degli errori negli algoritmi di analisi;

- ci sono degli errori nell'utilizzo dei software informatici;

- ci sono errori nella fase di comunicazione dei risultati;

- le informazioni sono state condivise con persone non autorizzate o più in generale ci sono state violazioni nella sicurezza dei dati;

- ci sono stati errori in fase di raccolta dei dati che vanno contro le normative vigenti.

3) Quali sono le 11 aree tematiche del Data Management secondo il DMBok2?

- Data Governance

- Data Architecture

- Data Modeling & Design

- Data Storage & Operations

- Data Security

- Data Integration & Interoperability

- Document & Content Management

- Reference & Master Data

- Data Warehousing & Business Intelligence

- Metadata

- Data Quality